

AUTORES
- Andrés Tobar - 23001175 - Samuel Marroquín - 23006593 - Daniel Pérez - 23002455

Sistema de Soporte a Decisiones Clínicas para la Detección de Cáncer de Mama mediante Aprendizaje Automático Regularizado

Seminario Profesional I, Facultad de Ingeniería, Universidad Galileo, Guatemala

REPOSITORIO EN GITHUB



01. Introducción

El diagnóstico temprano del cáncer de mama mediante el análisis de células suele depender de la interpretación visual que el especialista realiza bajo el microscopio, lo que a veces puede generar diferencias en los criterios médicos. Los sistemas de asistencia computacional basados en aprendizaje automático ayudan a estandarizar este proceso mediante reglas numéricas claras. Al evaluar enfermedades graves, estos sistemas deben diseñarse para reducir al mínimo los casos de cáncer no detectados (falsos negativos), asegurando un alto nivel de detección de la enfermedad sin clasificar de forma errónea a las pacientes sanas.

02. Descripción del Dataset

Se utilizó la base de datos de diagnóstico de cáncer de mama de Wisconsin, que cuenta con 569 registros de pacientes y 30 mediciones numéricas sobre la estructura de las células. El conjunto de datos original muestra que el 62.74% de los casos corresponden a diagnósticos benignos (357 muestras) y el 37.26% a malignos (212 muestras). Para evaluar el sistema de forma objetiva, los datos se dividieron en dos grupos: un 80% para entrenar y ajustar los modelos, y un 20% que se guardó por completo para realizar una prueba final con datos nuevos.

Subconjunto de Datos	Casos Benignos (0)	Casos Malignos (1)	Total de Muestras
Entrenamiento (80%)	62.64%	37.36%	455
Prueba (20%)	63.16%	36.84%	114

03. Metodología

El proceso se estructuró en tres etapas independientes para asegurar que el modelo no memorizara los datos de prueba y pudiera generalizar correctamente:

- Eliminación de datos repetidos:** Al medir una célula, características como el radio, el perímetro y el área aportan casi la misma información. El algoritmo detectó estas repeticiones (correlaciones mayores a 0.85) y eliminó las 12 variables que tenían menor relación directa con el diagnóstico final, dejando solo 18 características independientes.
- Normalización:** Las 18 mediciones restantes se ajustaron matemáticamente a la misma escala. Esto evita que las variables con números grandes dominen el análisis sobre aquellas con valores pequeños.
- Búsqueda del mejor modelo:** Se configuraron 5 algoritmos distintos utilizando un sistema de validación por bloques (5 folds). Las configuraciones de cada modelo se ajustaron automáticamente con el objetivo principal de maximizar la detección de la clase maligna.

Modelos utilizados: Regresión logística, Support Vector Machine (SVM), Random Forest, K-Nearest Neighbors (KNN) y Decision Tree

04. Resultados

Durante las pruebas internas, la Regresión Logística y el SVM obtuvieron la mayor tasa de detección de casos malignos (95.88%). Se seleccionó la Regresión Logística como el modelo definitivo debido a que mostró un mejor balance en el resto de las métricas de control.

Modelo Evaluado	Detección (Recall)	Balance (F1)	Precisión General (AUC)	Identificación de Sanos (Specificity)
Regresión Logística	95.88%	96.17%	99.54%	97.89%
SVM (Kernel RBF)	95.88%	94.77%	99.11%	96.14%
Random Forest	92.94%	93.77%	98.96%	96.84%
KNN	91.18%	94.80%	98.16%	99.30%
Árbol de Decisión	90.00%	90.80%	92.57%	95.09%

Al evaluar el modelo definitivo con el 20% de los datos que se habían reservado, se confirmaron los siguientes resultados:

- Detección de casos malignos (recall):** 95.2%
- Identificación de pacientes sanas (specificity):** 98.6%
- Casos de cáncer no detectados (Falsos Negativos):** Únicamente 2 pacientes.

05. Conclusiones

- Los modelos matemáticos lineales resultaron más estables y precisos para clasificar estas mediciones celulares que los algoritmos complejos basados en árboles de decisión.
- Las variables con mayor peso para identificar la enfermedad fueron el perímetro extremo de la célula (**worst perimeter**) y la variación en el tamaño del radio (**radius error**). Esto coincide con los criterios médicos tradicionales, donde la irregularidad en las formas y el descontrol en el crecimiento celular son señales directas de sospecha.
- La existencia de 2 falsos negativos confirma que esta herramienta debe usarse como un apoyo para el especialista y nunca como un sustituto del criterio médico.

06. Mejoras a Futuro

- Validación con datos nuevos:** Probar el algoritmo con expedientes médicos actuales de centros de salud locales para confirmar que mantenga su precisión a lo largo del tiempo.
- Análisis directo de imágenes:** Combinar las mediciones numéricas actuales con el análisis automático de las imágenes microscópicas mediante modelos de visión por computadora.
- Criterios moleculares:** Incorporar datos sobre receptores hormonales y factores genéticos para complementar la información geométrica de las células y lograr un perfil más completo.

